Prediksjon av brystkreft

Martin A. H. Pedersen, 29.10.26

1: BESKRIV PROBLEMET

OMFANG / *SCOPE*

Målet med prosjektet er å utvikle en modell for å klassifisere svulster som enten er ondartede eller godartede basert på medisinske målinger fra celleprøver. Denne problemstillingen er passende for maskinlæring fordi vi har numeriske features (målinger) og binær klassifisering (ondartet/godartet).

Maskinlæring er en god løsning fordi problemet består av mange variabler, og antall eksempler er stort nok til at statistiske metoder kan lære mønstre som er vanskelige å fange med manuelle regler. I praksis kan modellen brukes som et verktøy for radiolog til å finne prioritering på pasienter som burde sendes til videre undersøkelse.

METRIKKER

I dette prosjektet har jeg bestemt å fokusere på recall metrikken for å vurdere modellene, siden dette er i medisinsk sammenheng. Vi ønsker å kunne fange opp alle positive resultater (ondartet svulst) og ønsker derfor minimalt med falske negativer. Etter å ha fått best mulig recall kan man fokusere på accuracy for å gjøre modellen enda bedre med å minske falske positiver, som da igjen kan spare masse ressurser for undersøking av pasienter som ikke trenger det. Ettersom at recall er den viktigste metrikken, har jeg valgt å bare fokusere på det i dette prosjektet.

2: DATA

Jeg benytter brystkreftdatasettet fra scikit-learn til å trene modellen, som er et klassisk og veldig enkelt binært klassifiseringsdatasett. Datasettet er opprinnelig hentet fra Breast Cancer Wisconsin. Featurene er utregnet fra en digitalisert avbildning av finnålsprøve (FNA) av brystmasse. De beskriver karakteristikken av cellekjerner på avbildningen. Settet består av 569 instanser og 30 features. (Wolberg et al., 1995)

3: MODELLERING

Prosjektet sammenligner flere klassifikasjonsmodeller på mean recall verdien for å bestemme den best ytende modellen. Modellene som sammenlignes er LinearSVC, KNeighborsClassifier, CalibratedClasifierCV, RandomForestClassifier, GaussianNB, og VotingClassifier med alle inkludert. Modellene blir kjørt gjennom repeatedKFold med 5 til 10

folds repetert 5 ganger hver. Score for accuracy, recall, precision, og f1 er lagret, og på slutten utregnes gjennomsnitt (mean) for hver score. Så sammenlignes mean recall og den beste kategorien testes alle modellene der mot test settet som blir satt av før treningen. Derfra velger jeg den beste modellen på recall og lagrer den.

Navn	Accuracy	Recall	Precision	f1
linear_svc	0.9647	0.9754	0.9688	0.9716
knn	0.9632	0.9871	0.9553	0.9706
svc_rbf	0.9707	0.9756	0.9776	0.9762
rfc	0.9573	0.9704	0.9618	0.9656
nb	0.9369	0.9586	0.9419	0.9495
ensemble	0.9708	0.9824	0.9712	0.9764

Vinnende estimator: knn

	precision	recall	f1-score	support
0	1.00	0.93	0.96	42
1	0.96	1.00	0.98	72
accuracy			0.97	114
macro avg	0.98	0.96	0.97	114
weighted avg	0.97	0.97	0.97	114

4: DEPLOYMENT

Modellen blir deployed gjennom gradio, og den gir deg valg mellom hva modell i modell mappen som skal deployes, og henter så ut feature navnene og lager til input textbox for alle. Så kan man legge inn verdiene og få ut en prediksjon.

5: REFERANSER

Wolberg, W., Mangasarian, O., Street, N. & Street, W. (1995). Breast Cancer Wisconsin (Diagnostic) [Datasett]. UC Irvine Machine Learning Repository. https://doi.org/10.24432/C5DW2B

Khourdifi, Y., Bahaj, M. (2018) Applying Best Machine Learning Algorithms for Breast Cancer Prediction and Classification. IEEE. https://doi.org/10.1109/ICECOCS.2018.8610632